线性代数笔记

> **写在前面：**
> 这份讲义是笔者在学习时的一些思考和题目复盘。尤其想说的是，在2025-2026年的期末考里，讲义里不少核心思路和题目都“押中”了。
>
> **关于这份讲义：**
> 笔记的初稿是笔者自己整理的，后来在Gemini的帮助下重新梳理了逻辑、调整了排版。
>
> 比起复杂的行列式计算，笔者总觉得**几何直觉（Geometric Intuition）** 更自然，也更能帮助理解本质。所以如果你在读的时候，发现里面有不少从几何角度出发的解释——嗯，那大概就是笔者个人偏好了。

—— By 溺水的小丑鱼

🛫 第 0 章：矩阵乘法的本源 (The Origins)

> 可以用以下五种视角进行矩阵运算的理解。

0.1 矩阵乘向量：Ax 的两种核心视角

设 $A = (\mathbf{c}_1 \quad \mathbf{c}_2 \quad \dots \quad \mathbf{c}_n)$，其中 $\mathbf{c}_i$ 是列向量。

视角 A：列的线性组合 (The Column Picture) —— 最重要！

$$A\mathbf{x} = (\mathbf{c}_1 \quad \mathbf{c}_2 \quad \dots \quad \mathbf{c}_n) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = x_1\mathbf{c}_1 + x_2\mathbf{c}_2 + \cdots + x_n\mathbf{c}_n$$

- **直觉：** Ax 是对 A 的**列向量**进行线性组合。
- **应用：**
  - **解方程 $Ax = b$：** 实际上是在问“能不能用 A 的列向量组合出 b？”（即 b 是否在列空间里）。
  - **列空间 $C(A)$：** 就是所有这些组合 Ax 构成的集合。

视角 B：行的点积 (The Row Picture)

$$A\mathbf{x} = \begin{pmatrix} \mathbf{r}_1^T \\ \vdots \\ \mathbf{r}_m^T \end{pmatrix} \mathbf{x} = \begin{pmatrix} \mathbf{r}_1^T \cdot \mathbf{x} \\ \vdots \\ \mathbf{r}_m^T \cdot \mathbf{x} \end{pmatrix}$$

- **直觉：** 看作 x 在 A 的每一行方向上的投影。
- **应用：** 在 $Ax = 0$ 中，意味着 x 必须**垂直**于 A 的每一行（所以零空间 $\perp$ 行空间）。

0.2 向量乘矩阵：$y^T A$

$$\mathbf{y}^T A = \begin{pmatrix} y_1 & \dots & y_m \end{pmatrix} \begin{pmatrix} \mathbf{r}_1^T \\ \vdots \\ \mathbf{r}_m^T \end{pmatrix} = y_1 \mathbf{r}_1^T + \cdots + y_m \mathbf{r}_m^T$$

- **直觉：** $y^T A$ 是对 A 的**行向量**进行线性组合。
- **口诀：** **左乘行组合，右乘列组合。**

0.3 矩阵乘矩阵：AB 的四种视角

设 $A_{m\times n}$，$B_{n\times p}$

视角 A：列操作 (Column-wise) —— A 作用于 B 的列

把 B 看作一堆列向量 $\begin{pmatrix} \mathbf{b}_1 & \dots & \mathbf{b}_p \end{pmatrix}$。

$$AB = A \begin{pmatrix} \mathbf{b}_1 & \dots & \mathbf{b}_p \end{pmatrix} = \begin{pmatrix} A\mathbf{b}_1 & \dots & A\mathbf{b}_p \end{pmatrix}$$

- **直觉：** AB 的第 j 列，是 A 对 B 的第 j 列做变换。
- **结论：** **AB 的列空间是 A 的列空间的子空间。**

视角 2：行操作 (Row-wise) —— B 作用于 A 的行

把 A 看作一堆行向量。

$$AB = \begin{pmatrix} \mathbf{a}_1^T \\ \vdots \\ \mathbf{a}_m^T \end{pmatrix} B = \begin{pmatrix} \mathbf{a}_1^T B \\ \vdots \\ \mathbf{a}_m^T B \end{pmatrix}$$

- **直觉：** AB 的第 i 行，是 B 对 A 的第 i 行做组合。
- **结论：** **AB 的行空间是 B 的行空间的子空间。**

视角 3：列乘行 (Outer Product Expansion) —— 高阶大招

这是谱分解和SVD的灵魂。

$$AB = \sum_{k=1}^{n} (\text{A的第k列}) \times (\text{B的第k行}) = \mathbf{c}_1 \mathbf{r}_1^T + \mathbf{c}_2 \mathbf{r}_2^T + \cdots + \mathbf{c}_n \mathbf{r}_n^T$$

- **直觉：** 矩阵乘法是 n 个**秩1矩阵**的和。
- **应用：**
  - **谱分解：** $A = \sum \lambda_i q_i q_i^T$ 其实就是这个视角。
  - **SVD：** $A = \sum \sigma_i u_i v_i^T$ 也是这个视角。

- 如果只需近似矩阵，取前几项相加即可（主成分分析）。

0.4 变换的黄金法则 (The Golden Rule)

这是 Gilbert Strang 老爷子反复强调的：

> Left Multiply = Row Operation (左乘做行变换)
>
> Right Multiply = Column Operation (右乘做列变换)

- 想对 A 做行变换（高斯消元）？

  在 A 的左边乘一个初等矩阵 E。

  $$EA = \text{对A的行进行组合}$$

- 想对 A 做列变换?

  在 A 的右边乘一个初等矩阵 E。

  $$AE = \text{对A的列进行组合}$$

举个栗子🌰：

- $A^{-1}A = I$： 用 A^{-1} 在左边不断乘，相当于做初等行变换把 A 变成 I。
- $AP = B$： P 在右边，说明 B 是 A 的列的重新排列或组合（比如交换两列）。

🚀 第一章：分块矩阵与行列式 (The Block Art)

1.1 分块对角/反对角矩阵求逆

遇到分块矩阵，不要死算，看结构。

- **分块对角阵求逆：** 直接对角线求逆。

$$\begin{pmatrix} A_1 & & \\ & \ddots & \\ & & A_n \end{pmatrix}^{-1} = \begin{pmatrix} A_1^{-1} & & \\ & \ddots & \\ & & A_n^{-1} \end{pmatrix}$$

- **分块反对角阵求逆： 注意！** 逆矩阵的顺序是反过来的，且位置维持反对角。

$$\begin{pmatrix} & & A_1 \\ & \cdots & \\ A_n & & \end{pmatrix}^{-1} = \begin{pmatrix} & & A_n^{-1} \\ & \cdots & \\ A_1^{-1} & & \end{pmatrix}$$

1.2 舒尔补公式 (Schur Complement) —— 行列式降维神器

口诀： 提主元，扣尾款。

当 A 可逆时（以 A 为主元）：

$$\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |A| \cdot |D - CA^{-1}B|$$

当 D 可逆时（以 D 为主元）：

$$\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |D| \cdot |A - BD^{-1}C|$$

> **直觉来源：** 这本质上是分块高斯消元：
>
> $$\begin{pmatrix} I & 0 \\ -CA^{-1} & I \end{pmatrix} \begin{pmatrix} A & B \\ C & D \end{pmatrix} = \begin{pmatrix} A & B \\ 0 & D - CA^{-1}B \end{pmatrix}$$

1.3 降阶公式 (Sylvester's Determinant Identity)

当矩阵维度不同时（$A_{m\times n}, B_{n\times m}$），这是连接两个维度的桥梁。

$$|\lambda E_m - AB| = \lambda^{m-n} |\lambda E_n - BA|$$

特例（$\lambda = 1$）：

$$|E_m - AB| = |E_n - BA|$$

> **应用：** 如果 A 是列向量 u， B 是行向量 v^T，则 AB 是大矩阵，BA 是标量！

1.4 秩1修正行列式 (Matrix Determinant Lemma)

这是上述降阶公式的推论，用于处理“单位阵+秩1矩阵”。

$$|A + \mathbf{u}\mathbf{v}^T| = |A|(1 + \mathbf{v}^T A^{-1}\mathbf{u})$$

常见考题形式（$A = I, u = \alpha, v = -\alpha$）：

$$|I - \alpha\alpha^T| = 1 - \alpha^T\alpha$$

🛠 第二章：矩阵求逆进阶 (Inverse Pro)

2.1 秩1修正求逆 (Sherman-Morrison Formula)

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^TA^{-1}}{1 + v^TA^{-1}u}$$

特例（当 $A = I$）：

$$(I - uv^T)^{-1} = I + \frac{uv^T}{1 - v^Tu}$$

> 记忆法：

1. 符号相反（左边加，右边减）。
2. 分母是标量 $1+\text{trace}$。
3. 分子被 A^{-1} 夹在中间。

2.2 二阶矩阵求逆口诀

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

> **口诀：** 主对调，副变号，除以行列式。

📈 第三章：秩与不等式 (Rank & Inequalities)

3.1 秩的重要连等式

$$r(A) = r(A^TA) = r(A^T) = r(AA^T)$$

> **推论：** $Ax=0$ 与 $A^TAx=0$ 是同解方程组。（最小二乘法的理论基础）

3.1.0 拓展：投影矩阵与最小二乘

> 现实世界是不完美的。
>
> 当方程组 $Ax=b$ 无解时（比如 b 不在 A 的列空间里），工程思维不是“两手一摊”，而是“退而求其次”。
>
> 我们找不到精确解，但我们可以找“最近的解”(误差最小的解)。

3.1.1 最小二乘法 (Least Squares)

- **问题：** b 飞出去了，不在 A 的管辖范围（列空间）里。
- **目标：** 在 A 的列空间里找一个替身 p，让 p 离 b 最近。几何上，这意味着 $b-p$（误差向量 e）必须**垂直**于 A 的列空间。
- **核心方程 (Normal Equation)：**

$$A^TA\hat{x} = A^Tb$$

3.1.2 投影矩阵 (Projection Matrix P)

- 公式：

$$P = A(A^TA)^{-1}A^T$$

  (推导：因为 $p=A\hat{x}$，把上面解出来的 $\hat{x}$ 带进去即得)
- 若 A 为列向量 a（投影到直线）：

$$P = \frac{aa^T}{a^T a}$$

3.1.3 灵魂性质：幂等性 ($P^2 = P$)

- **代数意义：** $P^2 = P \cdot P = P$。
- **几何直觉：**
  - 把一个向量投影到桌面上（变成了影子）。
  - 再对这个影子做一次投影。
  - **结论：** 投影两次 = 投影一次。

3.2 秩的不等式链条

- **和的秩：** $r(A+B) \le r(A) + r(B)$
- **积的秩：** $r(AB) \le \min\{r(A), r(B)\}$
- **分块矩阵的秩：**

$$\max\{r(A), r(B)\} \le r(A \quad B) \le r(A) + r(B)$$

$$r\begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} = r(A) + r(B)$$

$$r\begin{pmatrix} A & 0 \\ C & B \end{pmatrix} \ge r(A) + r(B)$$

- **西尔维斯特不等式 (Sylvester)：** $r(AB) \ge r(A) + r(B) - n$ （其中 $A_{m\times n}, B_{n\times s}$）

🌀 第四章：特征值与对角化 (Eigenvalues)

4.0 特征值两大结论

- **迹 (Trace)：** $\sum \lambda_i = \mathrm{tr}(A) = \sum a_{ii}$
- **行列式 (Determinant)：** $\prod \lambda_i = |A|$

4.1 普通矩阵可对角化判据

n 阶矩阵 A 可对角化 $\iff$ 有 n 个线性无关特征向量。

判别流程：

1. **无重根：** λ 互异 $\Rightarrow$ 必可对角化。
2. 有重根： 若 λ_i 是 k 重根，必须检查 几何重数 == 代数重数。

   即：$n - r(A - \lambda_i I) = k$。

   (缺一个特征向量都不能对角化！)

4.2 秩1矩阵的特征值 ($\alpha\beta^T$)

对于矩阵 $C = \alpha\beta^T$（秩为1）：

- **特征值 λ_1：** 等于迹，即 $\text{tr}(C) = \beta^T\alpha$。
- **其余特征值：** 全为 0。
- **特征向量：**
  - 对应非零特征值的特征向量是 α （$C\alpha = \alpha(\beta^T\alpha)$）。
  - 对应0特征值的特征向量是所有垂直于 β 的向量。

4.3 秩1修正矩阵 ($E - k\alpha\alpha^T$) 的特征值

这类矩阵在几何上对应“反射”或“压缩”，在Householder变换中极常见。

对于矩阵 $B = E - k\alpha\alpha^T$（E为单位阵）：

1. **特征值：**
   - **主特征值：** $\lambda_1 = 1 - k(\alpha^T\alpha)$ （对应特征向量 α）。
   - **重特征值：** 其余 $n-1$ 个特征值均为 1 （对应特征向量为所有垂直于 α 的向量）。
2. **行列式：** $|B| = \prod \lambda_i = 1 - k(\alpha^T\alpha)$。
3. **几何直觉：**
   - 矩阵只在 α 方向上进行了缩放（缩放倍数为 $1 - k|\alpha|^2$）。
   - 在垂直于 α 的平面上，它就是单位阵 E（没动）。

> **一般推广 (Rank-1 Update)：**
>
> 对于 $C = A + \mathbf{u}\mathbf{v}^T$，若已知 A 的特征值，通常无法直接求 C 的特征值。
>
> 但如果 $A = \lambda I$（即 $C = \lambda I + \mathbf{u}\mathbf{v}^T$），则结论同上：
>
> 一个特征值为 $\lambda + \mathbf{v}^T\mathbf{u}$，其余为 λ。

4.4 实对称矩阵 (Real Symmetric Matrix)

最好的矩阵： $A = A^T$

1. 特征值全为**实数**。
2. 不同特征值对应的特征向量天然**正交**。
3. **必可正交对角化**：$Q^TAQ = \Lambda$ （Q为正交阵）。

4.5 谱分解的高阶处理 (Spectral Decomposition Pro)

实对称矩阵可以分解为 n 个投影矩阵的加权和：

$$A = \lambda_1 P_1 + \lambda_2 P_2 + \cdots + \lambda_n P_n$$

其中 $P_i = q_i q_i^T$ 是向第 i 个特征方向的投影矩阵。

4.6 特征向量速算外挂：叉积法 (Cross Product Trick)

仅适用于 3阶矩阵 ($n = 3$) 的手算神器。

当求 3×3 矩阵 A 对应特征值 λ 的特征向量 x 时，我们需要解 $(A - \lambda I)x = 0$。

传统方法： 高斯消元，容易算错。

叉积外挂：

1. 写出矩阵 $M = A - \lambda I$。
2. 因为 M 是奇异的（秩<3），它的行向量线性相关。
3. **任选** M 中两个**不共线**的行向量 r_1, r_2（看都不用看直接选非零且不成比例的两行）。
4. 直接计算叉积：$x = r_1 \times r_2$。
5. 得到的 x 即为特征向量（无需归一化）。

> 原理： $Mx = 0$ 意味着 x 垂直于 M 的每一行。三维空间中同时垂直于两个向量的方向，就是它们的叉积方向。
>
> 注意： 如果算出是 $\mathbf{0}$，说明选的两行共线了，换两行再叉即可。

📐 第五章：空间与变换 (Spaces & Geometry)

5.1 线性变换判定

映射 $T : V \to W$ 是线性的，必须同时满足：

1. **加法性：** $T(\alpha + \beta) = T(\alpha) + T(\beta)$
2. **齐次性：** $T(k\alpha) = kT(\alpha)$

> **避坑指南：**
>
> 1. 检查 $T(\mathbf{0})$ 是否为 $\mathbf{0}$。如果 $T(x) = x + b$ ($b \neq 0$)，那是平移，**不是**线性变换。
> 2. 出现平方、取模、行列式运算通常不是线性变换。

5.2 欧氏空间与内积判定

一个运算 $\langle \alpha, \beta \rangle$ 要成为内积，必须满足 4 条公理：

1. **对称性：** $\langle \alpha, \beta \rangle = \langle \beta, \alpha \rangle$
2. **线性（对第一变元）：** $\langle k\alpha + l\beta, \gamma \rangle = k\langle \alpha, \gamma \rangle + l\langle \beta, \gamma \rangle$
3. **非负性：** $\langle \alpha, \alpha \rangle \geq 0$
4. **严格正性：** $\langle \alpha, \alpha \rangle = 0 \iff \alpha = \mathbf{0}$

5.3 空间相等的证明

要证明线性空间 $V_1 = V_2$，通常只需证两点：

1. **包含关系：** $V_1 \subseteq V_2$ （即 V_1 的基都能被 V_2 的基线性表示）。
2. **维数相等：** $\dim(V_1) = \dim(V_2)$。

5.4 施密特正交化 (Gram-Schmidt Orthogonalization)

1. 核心直觉 (The Intuition)

给我们一组“乱七八糟、互相歪斜”的基 $\alpha_1, \alpha_2, \dots$，我们想把它们变成一组“横平竖直、互相垂直”的基 $\beta_1, \beta_2, \dots$

- **做法：** 也就是 **“去投影”**
- 保留第一个向量不动
- 第二个向量 = 原来的第二个 - (在第一个上的影子)
- 第三个向量 = 原来的第三个 - (在第一个上的影子) - (在第二个上的影子)

2. 计算公式 (The Algorithm)

设原向量组为 $\alpha_1, \alpha_2, \alpha_3$

- Step 1 (定基准)：

$$\beta_1 = \alpha_1$$

- Step 2 (去投影)：

$$\beta_2 = \alpha_2 - \frac{\langle \alpha_2, \beta_1 \rangle}{\langle \beta_1, \beta_1 \rangle} \beta_1$$

- Step 3 (如法炮制)：

$$\beta_3 = \alpha_3 - \frac{\langle \alpha_3, \beta_1 \rangle}{\langle \beta_1, \beta_1 \rangle} \beta_1 - \frac{\langle \alpha_3, \beta_2 \rangle}{\langle \beta_2, \beta_2 \rangle} \beta_2$$

> **最后一步（单位化）：** 如果题目要求“标准正交基”，别忘了最后除以模长：$\eta_i = \frac{\beta_i}{|\beta_i|}$。

3. 避坑指南 (The Trap)

1. **对象搞错：** 公式里减去的投影，是基于**已经正交化好的** β_1, β_2，**绝对不是**基于原来的 α_1, α_2！
   - *错解：* $\beta_3 = \alpha_3 - k_1\alpha_1 - k_2\alpha_2$ (❌)
   - *正解：* $\beta_3 = \alpha_3 - k_1\beta_1 - k_2\beta_2$
2. **计算量爆炸：** 如果在中间过程就急着“单位化”(带上了根号)，后面的计算会算到怀疑人生。
   - **策略：** 先只做正交化（只搞垂直，不管长短），算出清爽的整数 β_i，最后再统一除以模长。

📈 第六章：二次型与合同 (Quadratic Forms & Congruence)

> 如何理解？
>
> 二次型 $f(x) = x^T Ax$ 描述的是一个 **“地势图”**。
>
> 我们做的所有变换（配方、正交变换），都是在**不改变地形凹凸性质**的前提下，换个角度看这个地势。

1. **正定** = 碗（有最低点，稳定）
2. **负定** = 山峰（有最高点，不稳定）
3. **不定** = 马鞍面（鞍点，临界状态）

6.1 合同矩阵 (Congruent Matrices)

定义： 若存在可逆矩阵 C，使得 $C^T AC = B$，则称 A 与 B **合同**。

概念比较：合同 vs 相似

维度	相似 (Similarity)	合同 (Congruence)
公式	$P^{-1}AP = B$	$C^T AC = B$
核心不变量	**特征值** (λ), 迹, 行列式	**惯性指数** (p, q), 秩 (r)
物理意义	同一个**线性变换**在不同基下的表示	同一个**二次型(能量)**在不同坐标系下的表示
几何直觉	拉伸/旋转的倍数没变	**抛物面的开口方向和凹凸性**没变
联系	若 P 是**正交矩阵** ($P^T = P^{-1}$)，则相似 $\iff$ 合同	实对称矩阵必可合同于对角阵 $\text{diag}(\pm 1, 0)$

> 避坑：
>
> 两个矩阵 A, B 特征值相同，它们相似，也合同（因为特征值符号肯定一样）。
>
> 两个矩阵 A, B 特征值不同，但正负个数相同，它们合同，但不相似。

6.2 惯性定律 (Sylvester's Law of Inertia)

定理： 无论你用什么可逆变换（配方法、初等变换、正交变换）把二次型化为标准形，其**正系数的个数 (p)** 和 **负系数的个数 (q)** 是**永恒不变**的。

- **正惯性指数 (p)：** 能量增加的维度数量（向上的开口）。
- **负惯性指数 (q)：** 能量减少的维度数量（向下的开口）。
- **秩 (r)：** $r = p + q$ （起作用的总维度）。

6.3 正定性判据的全景图 (Positive Definiteness)

判断 A 是否正定（即 $x^TAx > 0$ 对任意 $x \neq 0$），其实是在问：**“这真的是一个碗吗？”**

四大判据（按解题优先级排序）：

1. 特征值判据（最本质）：

   全为正实数 ($\lambda_i > 0$)。

   (物理意义：在所有主轴方向上，都是往上弯的)
2. 顺序主子式判据（手算最快）：

   所有顺序主子式 $D_k > 0$ ($k = 1, \dots, n$)。

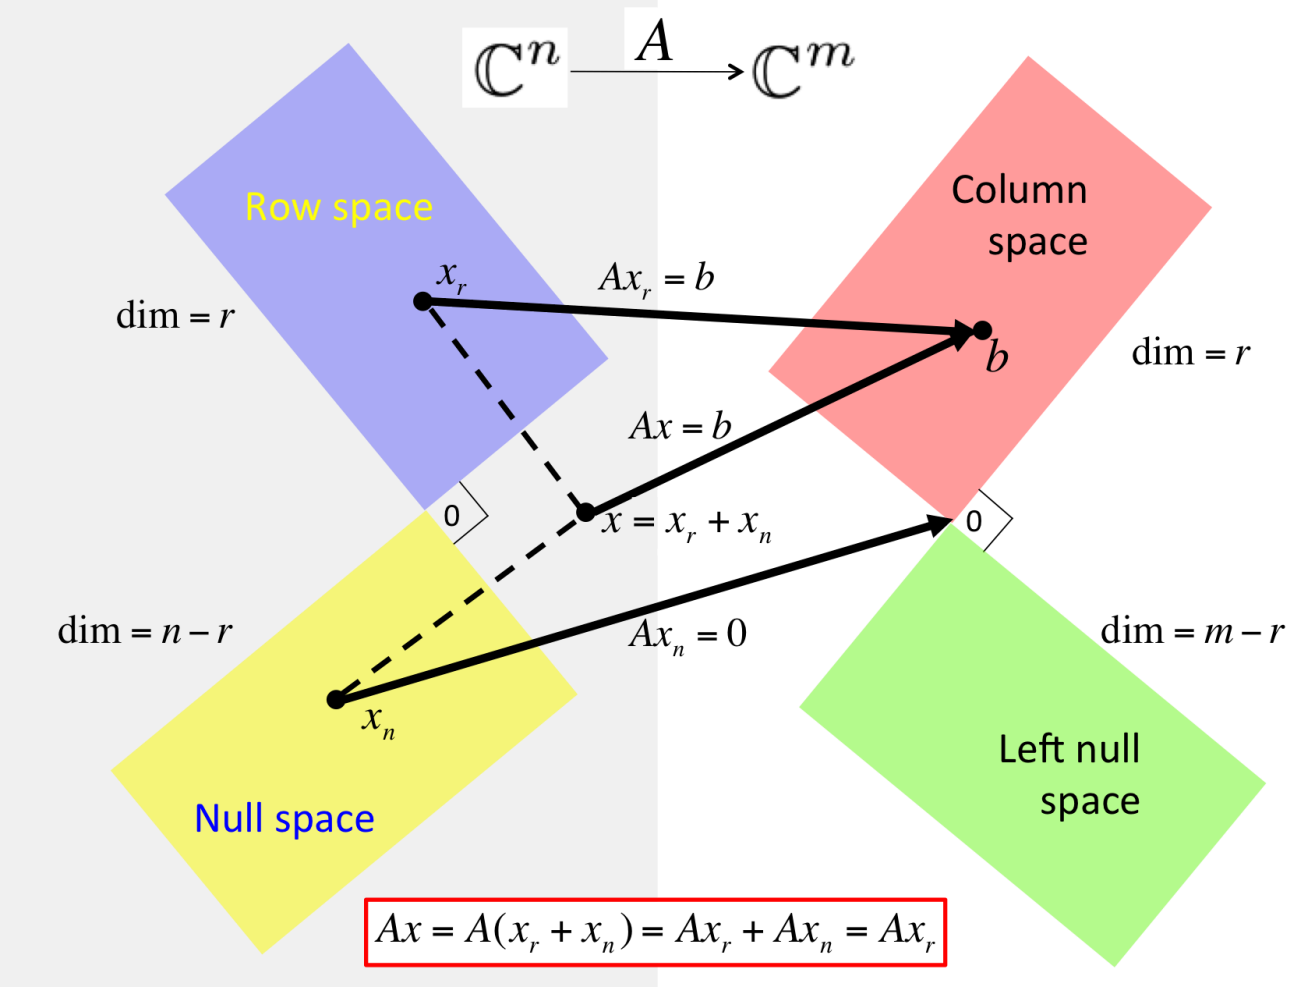
   (代数意义：高斯消元过程中，主元 pivot 永远为正)
3. 惯性指数判据（配方法）：

   正惯性指数 $p = n$ （或者标准形系数全正）。
4. 定义判据：

   $x^TAx > 0$。

🌌 终章：线性代数的四个基本空间 (The Big Picture)

> 核心图景：
>
> 任何一个 $m \times n$ 的矩阵 A，都在做一件事：
>
> 将 n 维输入空间 ($\mathbb{R}^n$) 里的向量，映射到 m 维输出空间 ($\mathbb{R}^m$)。
>
> 这个过程中，两个世界被精准地切割成了四块：



1. 输入世界的切割 ($\mathbb{R}^n$)

输入向量 x 被分解为两部分：$x = x_r + x_n$。

- **行空间 $C(A^T)$ (Row Space)：**
  - **维数：** r (秩)
  - **身份：** **“有效输入区”**。
  - **理解：** 只有落在这个空间里的分量，A 才会对它处理（拉伸、旋转）。这一部分的信息被保留并传递到了输出端。
- **零空间 $N(A)$ (Null Space)：**
  - **维数：** $n - r$
  - **身份：** **“无效输入区”** 或 **“信息的黑洞”**。
  - **理解：** 落在这里的分量，A 直接把它变成了 $\mathbf{0}$。这是解方程 $Ax = 0$ 的所有解。
  - **几何关系：** **它与行空间正交互补** ($N(A) \perp C(A^T)$)。
  - **工程意义：** 系统中无法被观测到的状态，或者被滤波器滤掉的噪声。

2. 输出世界的切割 ($\mathbb{R}^m$)

输出向量 b (或目标向量) 也就处于两个区域之一。

- **列空间 $C(A)$ (Column Space)：**
  - **维数：** r (秩)

- **身份：** **“可达区域”** (Reachable Set)。
- **理解：** 系统 Ax 能产生的所有可能的输出。如果 b 在这里，方程有解。

- **左零空间 $N(A^T)$ (Left Null Space)：**
  - **维数：** $m-r$
  - **身份：** **“不可达的禁区”**。
  - **理解：** 这里的向量 y 满足 $A^Ty=0$ (即 $y^TA=0$，所以叫“左”零空间)。
  - **几何关系：** **它与列空间正交互补** ($N(A^T) \perp C(A)$)。
  - **工程意义：** **“误差空间”**。当我们做最小二乘法解不可解方程 $Ax=b$ 时，最小误差向量 $e=b-p$ 就必须死死地躺在这个左零空间里（因为它必须垂直于列空间）。

3. 总结：线性变换的全过程

当矩阵 A 作用于向量 x 时，实际上发生了这三步：

1. **分解：** 把 x 拆成 **行空间分量** (有效) 和 **零空间分量** (无效)。
2. **毁灭：** 零空间分量直接被消灭，变成 0。
3. **映射：** 行空间分量被一对一地、可逆地映射到了 **列空间**。

> 维度守恒定律 (Rank-Nullity Theorem)：
>
> 输入的总维度 n = 活下来的维度 (r) + 死掉的维度 ($n-r$)。

4. 为什么叫“左”零空间？(记忆技巧)

- **Null Space:** $Ax=0$ (x 在 A 的右边)
- **Left Null Space:** $y^TA=0$ (y^T 在 A 的左边)
- 这实际上就是 A^T 的零空间。

> 最后，感谢学科营的辅导员们，在讨论中给予的耐心指导和启发；也感谢搬运并翻译 MIT 18.06 课程视频的 B 站 up 主，让经典的课程得以被更多人看见和学习。
> 正是这些来自师长、同好与开源分享的帮助，让这段学习旅程更加丰满。
>
> 希望这份带着个人视角与几何偏好的梳理，能给你带来一些不一样的启发。
> **Enjoy the Journey of LINEAR ALGEBRA!** 💐

学习资料参考：

1. 致大一新生【2024新版】 - 知乎
2. 麻省理工学院—线性代数课（完整版72讲）通俗易懂，绝对是线性代数课程天花板！
3. **高数数分代数学科营（SJTU园区）**
4. 【熟肉】线性代数的本质 - 01 - 向量究竟是什么？
5. Visual Kernel - YouTube

> 整理不易，如果发现笔误或是有更好的理解，欢迎传承！
> **祝学习顺利** ✨